人工智能 · 课堂笔记

人工智能

2025年4月19日 15:56

人工智能三大学派：符号学派、联结学派、行为学派

一、知识表示方法

状态空间法、问题归约法、谓词逻辑法、语义网络法

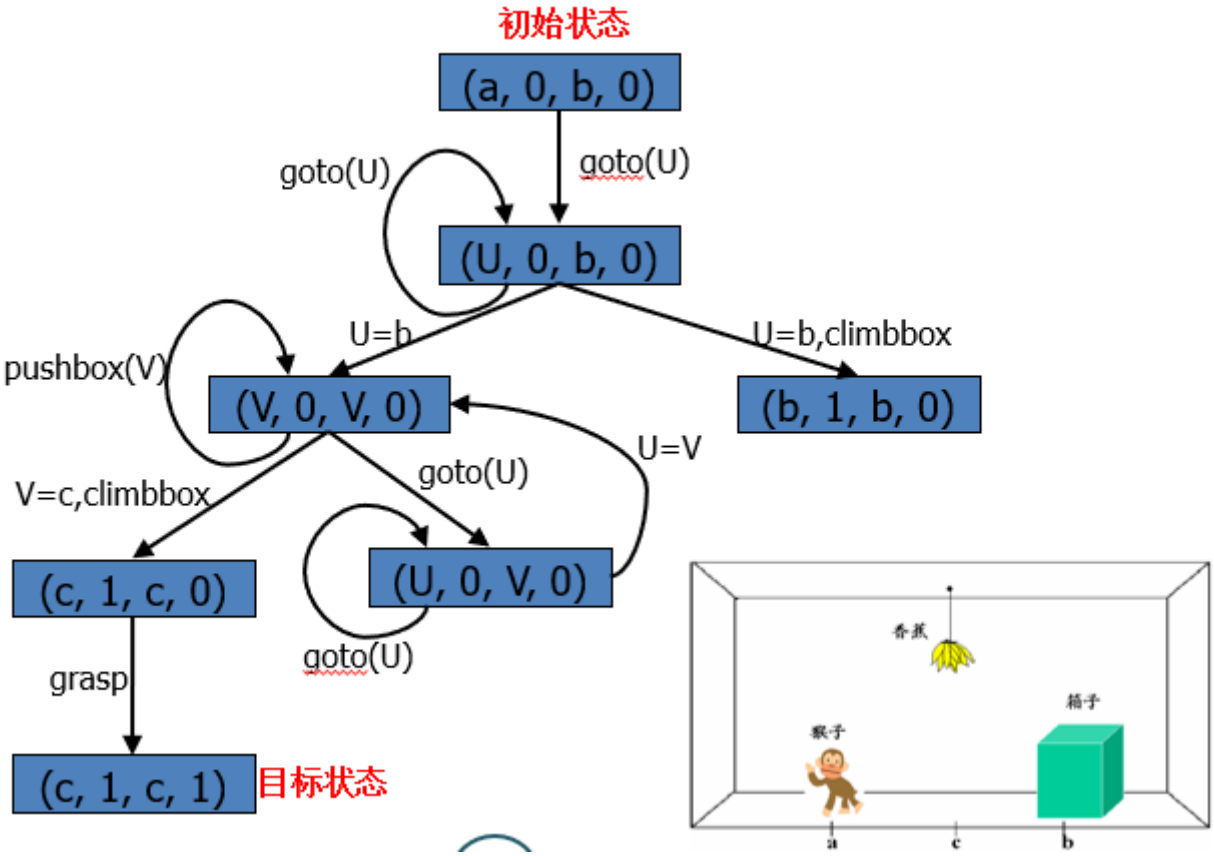


图 1

状态空间法三要素：状态、算符、状态空间

问题归约法：根据已知问题的描述，通过一系列变换把此问题变为一个子问题集合

可解节点（递归地）

✓终叶节点是可解节点（对应于本原问题）。

✓如果某个非终叶节点含有或后继节点，那么只要当其后继节点至少有一个是可解的时，此非终叶节点才是可解的。

✓如果某个非终叶节点含有与后继节点，那么只有当其后继节点全部为可解时，此非终叶节点才是可解的。

图 2

Part 1 | **Part 2** | Part 3 | Part 4

增加附加节点后的规范化与或图表示：

- 为了不出现既有与子节点又有或子节点的节点,使得状态图更规范,更容易被计算机所存储与处理,通常把某些附加节点引入此结构图.
  - 这样便使含有一个以上子问题的每个集合能够聚集在它们各自的父节点之下.
  - 其中,标记为N和M的附加节点分别作为集合{B,C}和{D,E,F}的唯一父节点,具有辅助问题描述的作用.

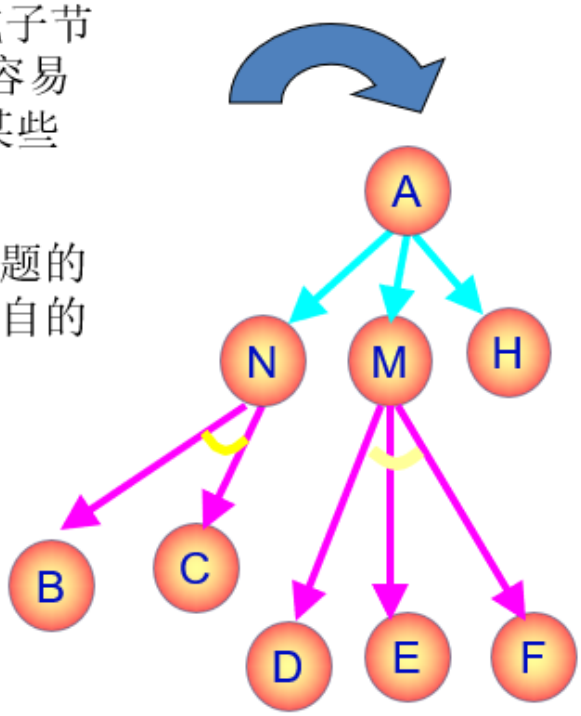


图 3

不可解节点

✓没有后裔的非终叶节点为不可解节点。

✓如果某个非终叶节点含有或后继节点，那么只有当其全部后裔为不可解时，此非终叶节点才是不可解的。

✓如果某个非终叶节点含有与后继节点，那么只要当其后裔至少有一个为不可解时，此非终叶节点才是不可解的。

图 4

P	Q	P∨Q	P∧Q	P→Q	~P	P↔Q
T	T	T	T	T	F	T
F	T	T	F	T	T	F
T	F	T	F	F	F	F
F	F	F	F	T	T	T

图 5

谓词逻辑法：谓词=谓词名+个体

置换是用变量、常量、函数置换项来替换变量，使该变量不在公式中出现

合一的定义：寻找项对变量的置换，以使两表达式一致

优点：自然：一阶谓词逻辑是一种接近于自然语言的形式语言系统，谓词逻辑表示法接近于人们对问题的直观理解

精确：谓词逻辑的真值只有“真”与“假”，其表示、推理都是精确的

灵活：知识和处理知识的程序是分开的，无须考虑处理知识的细节

严格：严格的形式定义及推理规则

缺点：知识表示能力差：只能表示确定性知识，而不能表示不确定性知识、过程性知识和启发式知识

知识库管理困难：缺乏知识的组织原则，知识库管理比较困难

存在组合爆炸：由于难以表示启发式知识，因此只能盲目地使用推理规则，这样当系统知识量较大时，容易发生组合爆炸

系统效率低：它把推理演算与知识含义截然分开，抛弃了表达内容中所含有的语义信息，往往使推理过程冗长，降低了系统效率

模块化：知识之间相对独立，这种模块性使得添加、删除、修改知识比较容易进行

容易实现：容易转换为计算机的内部形式，易于在计算机上实现

语义网络法：（节点1，链，节点2）类属关系、聚集关系、属性关系、推论关系、相近关系、方位关系、时间关系、构成关系

聚类关系与类属关系的主要区别：聚类关系一般不具备属性的继承性。如上述例子，手不一定具有人的各种属性。

一元关系、二元关系、多元关系（增加情况节点、增加动作节点、增加事件节点）

优点：结构性：把事物的属性以及事物间的各种语义联系显式地表示出来，是一种结构化的知识表示方法。在这种方法中，下层结点可以继承、新增、变异上层结点的属性。

联想性：本来是作为人类联想记忆模型提出来的，它着重强调事物间的语义联系，体现了人类的联想思维过程。

自索引性：把各接点之间的联系以明确、简洁的方式表示出来，通过与某一结点连结的弧可以很容易的找出与该结点有关的信息，而不必查找整个知识库。这种自索引能力有效的避免搜索时所遇到的组合爆炸问

题。

方法	初始问题	算符	目标	结果
状态空间法	状态	算符	目标状态	解答路径(path)
问题归约法	节点	弧	节点	解答树(tree)
谓词逻辑法	合式公式	子句集 (set of clause) 置换合一 消解反演	根节点	消解反演树 （根节点为NIL）
语义网络法	节点	链	目标网络	语义网络

图 6

自然性：这种带有标识的有向图，可比较直观地把知识表示出来，符合人们表达事物间关系的习惯，并且与自然语言语义网络之间的转换也比较容易实现。

缺点：非严格性：没有象谓词那样严格的形式表示体系，一个给定语义网络的含义完全依赖于处理程序对它所进行的解释，通过语义网络所实现的推理不能保证其正确性。

复杂性：语义网络表示知识的手段是多种多样的，这虽然对其表示带来了灵活性，但同时也由于表示形式的不一致，使得它的处理增加了复杂性。

二、搜索推理

搜索：根据问题的实际情况，不断寻找可利用知识，从而构造一条代价最小的推理路线，使问题得以解决的过程

根据搜索过程是否使用启发式信息：

盲目搜索：按预定的控制策略进行搜索，在搜索过程中获得的中间信息并不改变控制策略。由于搜索总是按预先规定的路线进行，没有考虑到问题本身的特性，因此这种搜索具有盲目性。包括宽度优先搜索、深度优先搜索、等代价搜索。

启发式搜索：搜索过程中加入与问题有关的启发性信息，用于指导搜索朝着最有希望的方向前进，加速问题的求解过程并找到最优解。主要涉及有序搜索、A*算法

根据问题的表示方式：状态空间搜索：基于问题到状态空间表示求解问题所进行的搜索。

与 / 或树搜索：基于问题的与 / 或树表示利用问题归约法来求解问题时所进行的搜索。

图搜索策略：

先把问题的初始状态作为当前扩展节点对其进行扩展，生成一组子节点。然后检查问题的目标状态是否出现在这些子节点中。若出现，则搜索成功，找到了问题的解；若没出现，则再按照某种搜索策略从已生成的子节点中选择一个节点作为当前

扩展节点。重复上述过程，直到目标状态出现在子节点中或者没有可供操作的节点为止。所谓对一个节点进行“扩展”是指对该节点用某个可用操作进行作用，生成该节点的一组子节点。

OPEN表存放带扩展节点的表，CLOSE表存放已被扩展的节点的表

盲目搜索：搜索过程中不使用与问题有关的经验信息、不重排OPEN表、搜索效率低、不适合大空间的实际问题求解,一般只适合于求解比较简单的一些问题

宽度优先搜索：以接近起始节点的程度依次扩展节点，OPEN表为队列（先进先出）

深度优先搜素：扩展最深节点，搜索沿着状态空间某单一路径从起始节点向下进行下去

等代价搜索：宽度优先搜索的一种推广，不是沿着等长度路径断层进行扩展，而是沿着等代价路径断层进行扩展。

启发式搜索：进行搜索技术可用于指导搜索过程，且与具体问题领域有关的信息

按照估价函数的大小对OPEN表排序 f(x) = g(x)+h(x) g(x)表示从初始节点S0到节点x的代价；h(x)是从节点x到目标节点Sg的最优路径的代价的估计

根据搜索过程中选择扩展节点的范围，将启发式搜索算法分为：

全局择优搜索算法： 从OPEN表的所有节点中选择一个估价函数值最小的一个进行扩展。

局部择优搜索算法：仅从刚生成的子节点中选择一个估价函数值最小的一个进行扩展。

A*算法的限制条件：f (x) = g (x) + h (x) g (x)大于0 h (x)不大于x到目标的实际代价

消解原理：对谓词演算公式进行分解和化简，消去一些符号，以求得导出子句。

子句集及其化简：消去蕴含符号、减少否定符号的辖域、对变量标准化、消去存在量词、化为前束形、把母式化为合取范式、消去全称量词、消去连词符号∧、更换变量名称

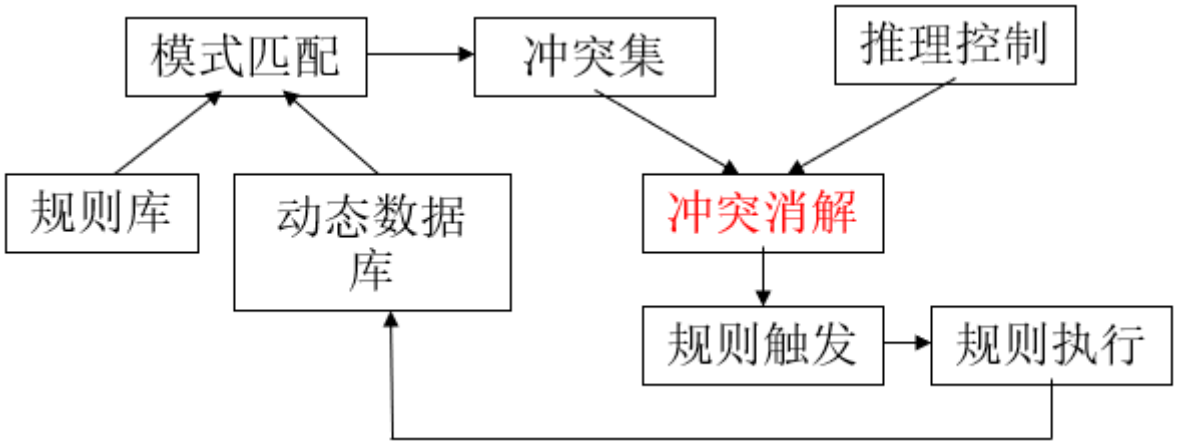


图 7

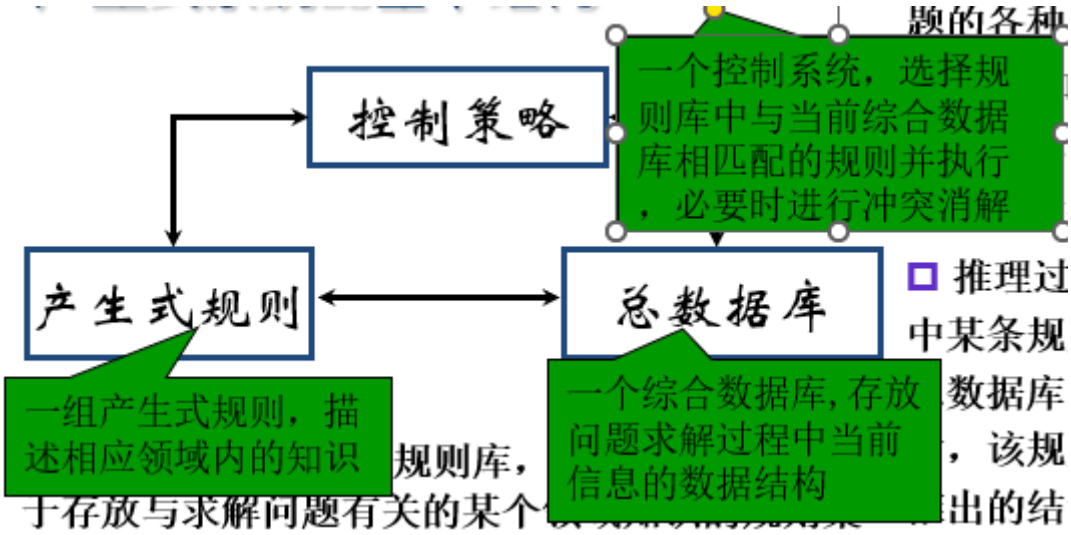


图 8

消解反演：化简子句集与结论的否定后生成反演树，结果为表示矛盾的空子句NIL

反演求解：（1）目标公式否定的子句，把它添加至目标公式的否定之否定子句中去，得重言式

（2）用下图的反演树进行消解，并在根部得到子句

（3）从根部求得答案，用此子句作为回答语句。

产生式系统：用来描述若干个不同的以一个基本概念为基础的系统。由总数据库(或全局数据库)、产生式规则和控制策略组成。

工作周期: 匹配, 选择, 执行三个阶段组成

控制系统的主要任务包括：选择匹配、冲突消解、执行操作、终止推理、路径解释

冲突解决策略：专一性排序、规则排序、数据排序、规模排序、就近排序、上下文限制

推理：正向推理（事实或数据驱动推理、前向链接推理）、逆向推理（目标驱动推理、逆向链接推理）和双向推理。

正向推理：从一组表示事实的谓词或命题出发，使用一组推理规则，来证明目标谓词公式或命题是否成立。

逆向推理：从表示目标的谓词或命题出发，使用一组规则证明事实谓词或命题成立，即提出一批假设目标，然后逐一验证这些假设。

双向推理：同时从表示目标向事实推理和从事实向目标推理，并在推理过程中的某个步骤，实现事实与目标的匹配。

三、计算智能

遗传算法：模仿生物遗传学（孟德尔，摩尔根）和自然选择机理（达尔文），通过人工方式所构造的一类优化搜索算法，是对生物进化过程进行的一种数学仿真，是进化计算的最重要的形式。

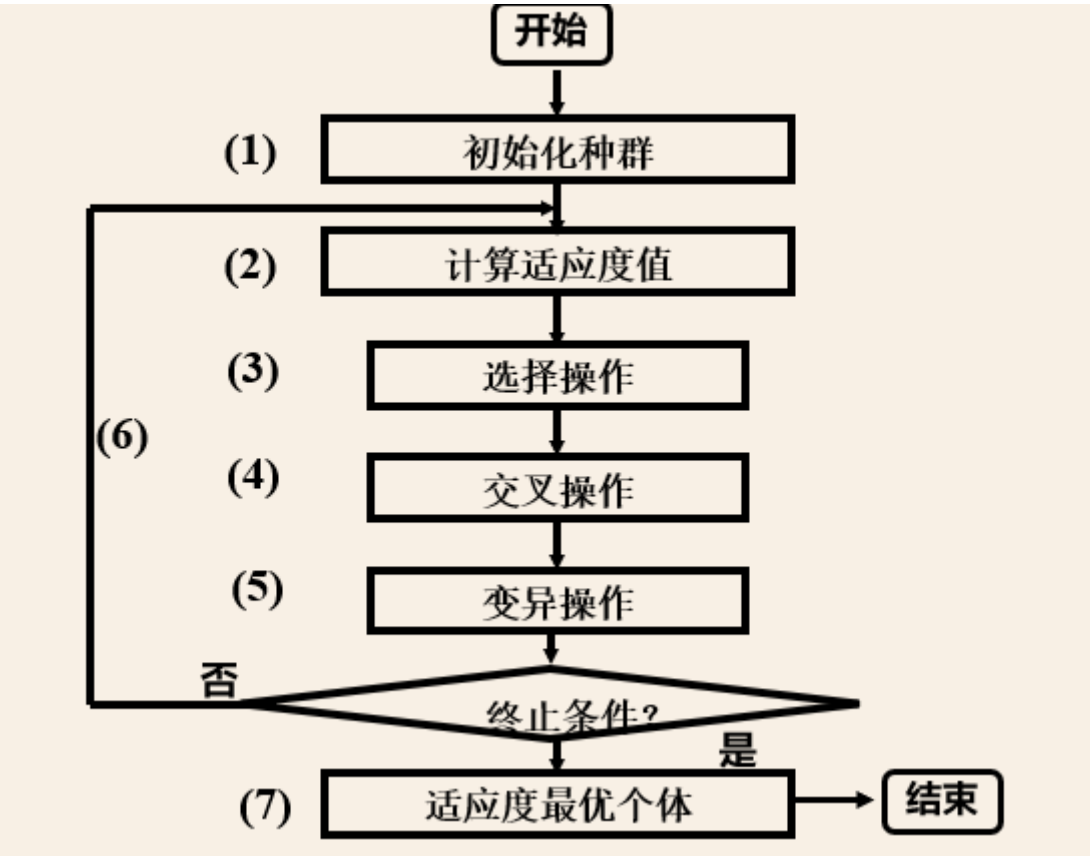


图 9

（1）选择作用：选择的目的是为了从当前群体中选出优良的个体，使它们有机会作为父代来繁殖下一代子孙，其作用是优胜劣汰。

（2）交叉作用：它同时对两个染色体的部分基因进行交换，是遗传算法中最主要的遗传操作，其作用是产生新解。

（3）变异作用：通常情况下变异操作是施加于种群内单个个体之上的，同生物界一样，遗传算法中的变异是个别染色体的局部变异，并且是偶尔发生的，其作用是随机偶然地产生新解。

在所有参数相同的情况下，遗传算法每次得到的最优解有所不同，这是因为

遗传算法每次都是随机产生初始种群，由于初始种群的不同，即使各参数都相同，每次迭代的结果都有所不同，因此得到的最优解有所不同，但相差不大，都是目标的近似解。

图 10

原理：搜索空间的一组有效解、选择得到的新群体、可行解的编码串、染色体的一个编码单元、染色体的适应值、染色体交换部分基因得到新染色体、染色体某些基因的数值改变

流程：算法流程图、染色体编码、群体初始化、适应值评价、选择算子、交配算子、变异算子、伪代码

编码：二进制编码、浮点数编码、格雷码、符号编码、多参数编码

群体初始化：随机数初始化

适应度评价：适应度函数

遗传操作：选择、交叉、变异

选择：赌轮选择机制（随机数）

交叉：对于每个染色体，如果Random(0, 1)小于Pc则表示该染色体可进行交配操作（其中Random(0, 1)为[0, 1]间均匀分布的随机数），否则染色体不参与交配直接复制到新种群中。

假设有八位长的两个体，产生一个在1到7之间的随机数c，假如现在产生的是3，将P1和P2的低三位交换。

变异：如果Random(0, 1)小于Pm（变异概率），则改变该基因的取值（其中Random(0, 1)为[0, 1]间均匀分布的随机数）。否则该基因不发生变异，保持不变。

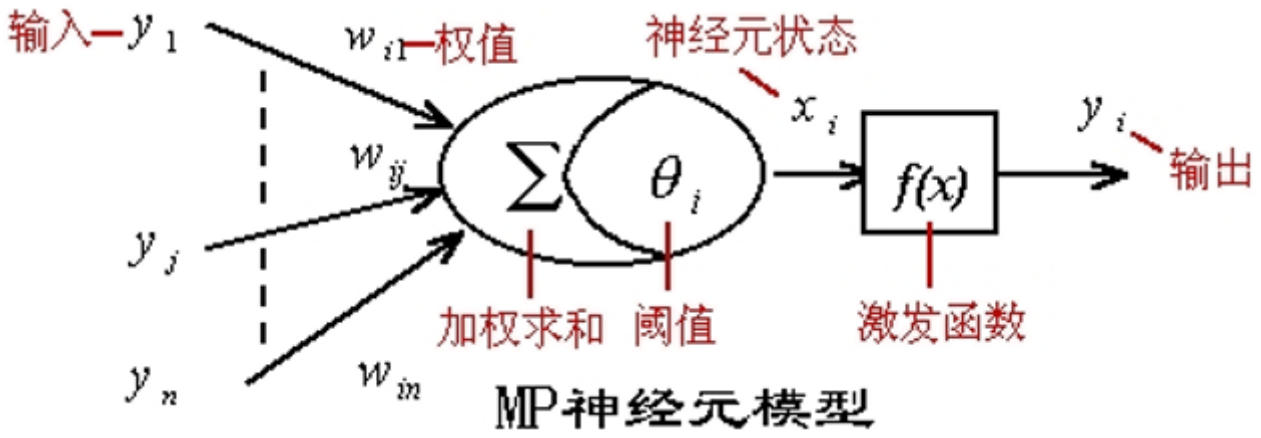


图 11

改变数码串的某个位置上的数码。码长为8的二进制编码，随机产生一个1~8之间的数k。假设现在k=5，对从右往左的第5位进行变异操作

神经元结构：胞体、树突、轴突、突触

胞体：神经细胞的本体，维持细胞生存功能，对输入信号进行处理，相当于CPU

树突：本体伸出分支，多根，长1mm左右，接收来自其他神经元的信号，输入端。

轴突：本体向外伸出最长一根分支，神经纤维，长1cm—1m，轴突上神经末梢将信号传给其它神经元，输出端。

突触：与另一个神经元相联系的特殊部位，各神经元间的接口，每个细胞体大约有103—104个突触。突触有兴奋型和抑制型两种。

非线性问题

Sigmoid函数：单调递增函数，关于(0, 0.5)中心对称，输出值的范围为(0, 1)

$$f(v)=\frac{1}{1+e^{-v}}$$

图 14

$$Tanh(x)=\frac{e^{x}-e^{-x}}{e^{x}+e^{-x}}=2\sigma(2x)-1, x\in\mathcal{R}$$

图 15

$$ReLU(x) = max(0, x), x \in \mathcal{R} \qquad f(x) = \begin{cases} x; x \geq 0 \\ 0; x < 0 \end{cases}$$

图 16

Tanh函数：输出值范围为(-1, 1)，关于(0, 0)中心对称

梯度消失问题

线性整流函数（ReLU函数）

Softmax函数：函数接受一个向量，并使用下列函数计算输出向量中每个元素的相应概率。

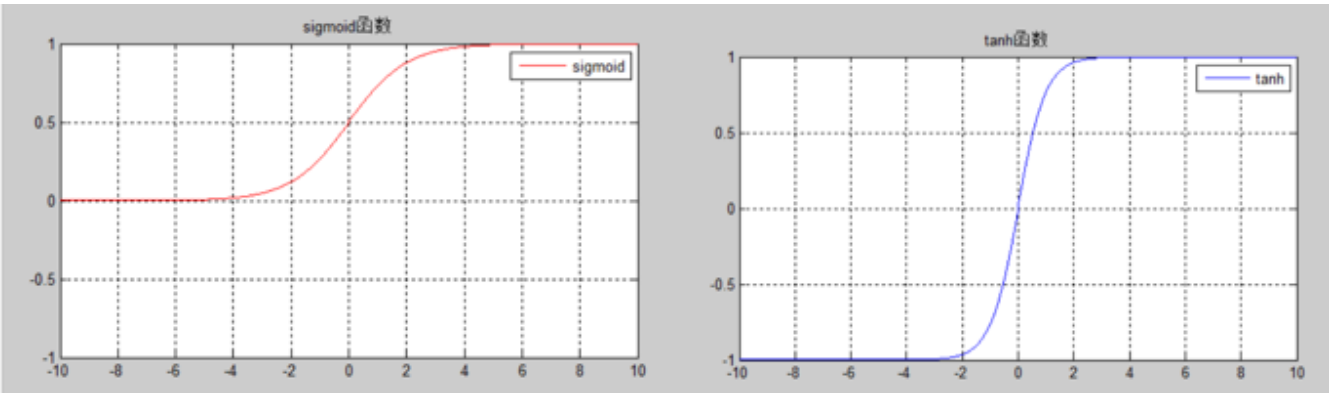


图 17

线性阈值单元：最简单的神经元，基本功能为线性划分

单个TLU只能解决线性可分问题

神经网络：多个神经元以一定的拓扑结构互连组成的网络

分为递归（反馈）网络、前馈网络

四、机器学习

分类是解决“这是什么?”的问题

聚类(Clustering) 解决的是事物分组的问题，目的是将类似的事物放在一起

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

图 18

$$\text{Precision} = \frac{TP}{TP + FP}$$

图 19

真正例(TP)：模型将正类别样本正确地预测为正类别。

真负例(TN) ：模型将负类别样本正确地预测为负类别。

假正例(FP) ：模型将负类别样本错误地预测为正类别。

假负例(FN) ：模型将正类别样本错误地预测为负类别。

准确率(Accuracy)：模型预测正确的结果所占的比例。

精确率(Precision): 在所有被预测为正的样本中实际为正的样本的概率

召回率(Recall)：针对原样本而言，在实际为正的样本中被预测为正样本的概率。

$$召回率 = \frac{TP}{TP + FN}$$

图 20

F1 得分：模型精准性与模型召回率综合指标。 2TP/(2TP+FP+FN)

基于距离的分类算法：有A，B，C三个类；有18个待分类的样例；通过计算每个类代表区域的中心来确定每个类的分类中心CA，CB，CC；通过计算待分类的样例到每个分类中心的距离就可以找出最相似的类。

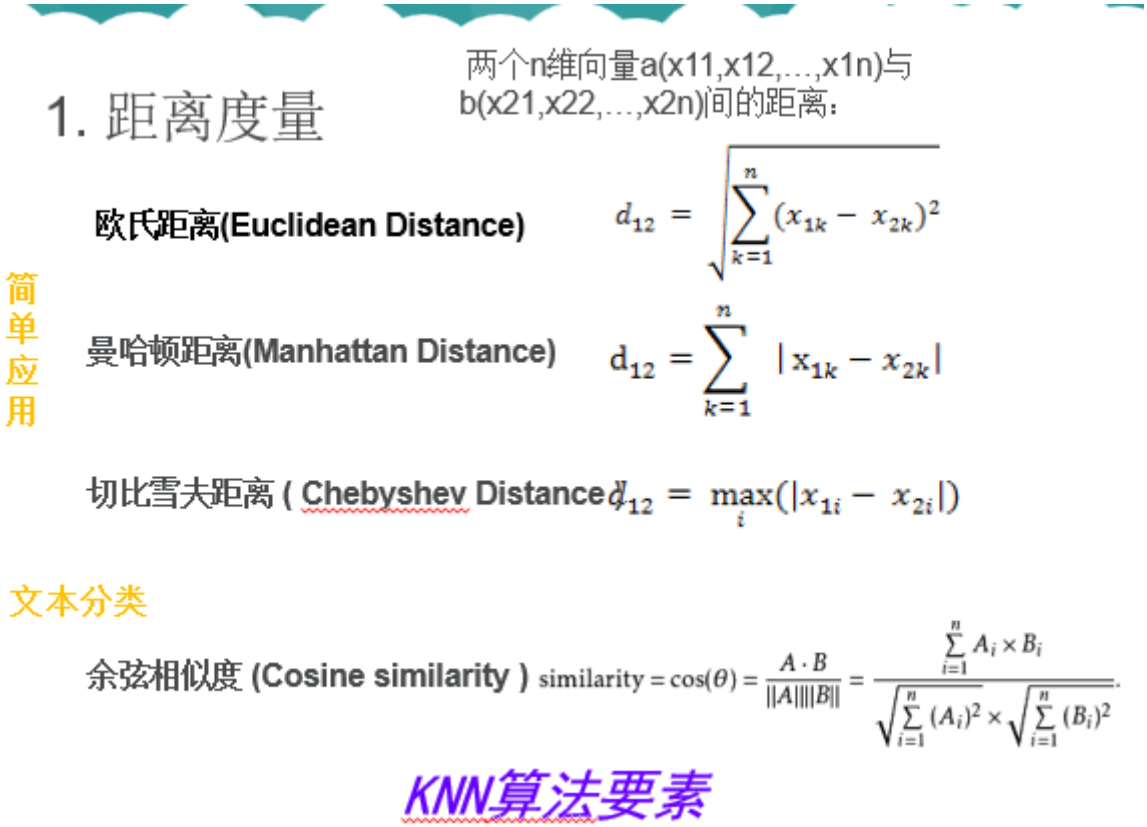


图 21

$$Entropy(S) = -\sum_{i=1}^{C} p_i \log_2(p_i)$$

其中，S表示样本集，

C表示样本集合中类别个数(只含有正负样本，则 C为2)，

p_i表示第 i 个类的概率，

(p_i可由类别i中含有样本的个数除以总样本数得到)

图 22

k-最近邻算法KNN：计算新样本与训练样本之间的距离，找到距离最近的K个邻居，根据这些邻居所属的类别来判定新样本的类别，如果属于同一个类别，那么新样本也属于这个类；否则，对每个候选类别进行评分，按照某种规则确定新样本的

类别。

决策树：一种典型的分类方法，将分类器表示成树状结构，然后使用决策树对新数据进行分类。

一个系统越是有序，信息熵就越低；反之，一个系统越乱，信息熵就越高。所以，信息熵也可以说是系统有序化程度的一个衡量。

信息增益:衡量属性区分训练样例的能力，是指当前熵与两个新群组经加权平均后的熵之间的差值

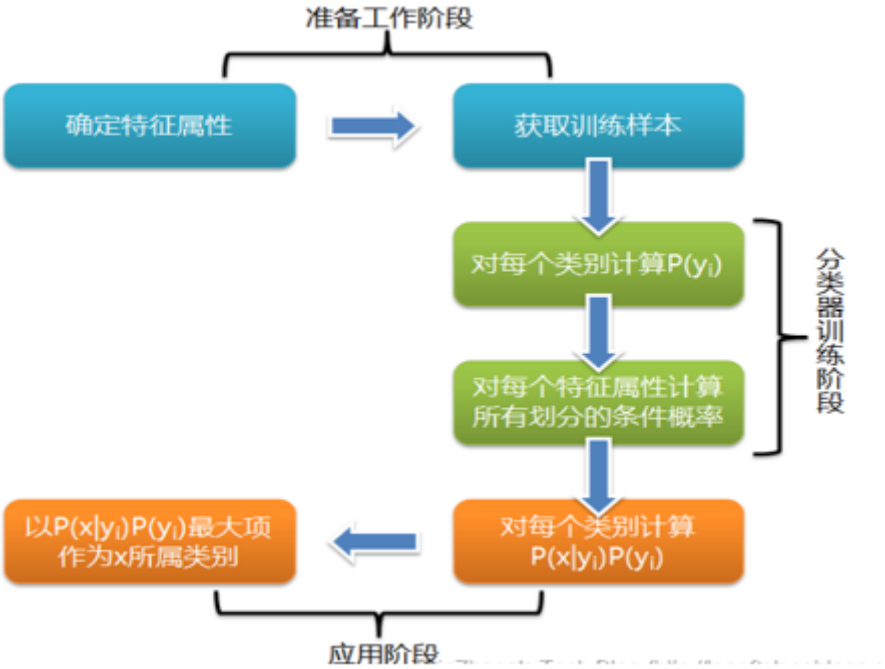


图 23

在多项式模型中，设某文档d=(t_1,t_2,…,t_k)，t_k是该文档中出现过的单词，允许重复，则

$$\text{先验概率}P(c)=\frac{\text{类c下单词总数}}{\text{整个训练样本的单词总数}}$$

$$\text{类条件概率}P(t_k|c)=\frac{\text{类c下单词}t_k\text{在各个文档中出现过的次数之和}+1}{\text{类c下单词总数}+|V|}$$

其中，V是训练样本的单词表（即抽取单词，单词出现多次，只算一个），|V|则表示训练样本包含多少种单词。

图 24

$$P(B|A)=\frac{P(A|B)P(B)}{P(A)}$$

图 25

$$\text{先验概率}P(c)=\frac{\text{类c下文件数}}{\text{整个训练本的文件总数}}$$

$$\text{条件概率}P(t_k|c)=\frac{\text{类c下单词}t_k\text{的文件数}+1}{\text{类c下文件数}+2}$$

在这里，m=2, p=1/2。

$$p(t_c|c=YES)=\prod p(t_c|c=yes)(1-p(t_i|c=yes)$$

- 将重复的词语都视为其只出现1次
- 更加简化与方便，但丢失了词频的信息，效果可能会差一些

图 26

选取信息增益最大的属性进行下次树枝的结点

贝叶斯定理：

朴素贝叶斯：基于贝叶斯条件概率定理的概率分类器，假设特征之间相互独立、彼此不相关

多项式模型：

伯努利模型：将重复的词语都视为其只出现一次

混合模型：在计算句子概率时，不考虑重复词语出现的次数，但是在统计计算词语的概率P时，却考虑重复词语的出现次数

K-Means：在最小化误差函数的基础上将数据划分为预定的类数K。该算法原理简单并便于处理大量数据。

随机选择k个点作为初始聚类的中心，由这个中心代表各个聚类

对任意一个样本，计算其到k个点的距离，将该样本归到距离最近的中心所在的聚类

计算聚类的平均值，即将聚类的中心移动到均值处

重复2、3步的迭代，直到聚类的中心不再移动，此时算法收敛，迭代结束

五、专家系统

专家系统：是一个含有大量的某个领域专家水平的知识与经验智能计算机程序系统，能够利用人类专家的知识和解决问题的方法来处理该领域问题；专家系统是一种模拟人类专家解决领域问题的计算机程序系统

一类包含知识和推理的智能计算机程序，应用于某一专门领域，拥有该领域相当数量的专家级知识，能模拟专家的思维，能达到专家级水平，能像专家一样解决困难和复杂的实际问题的计算机(软件)系统

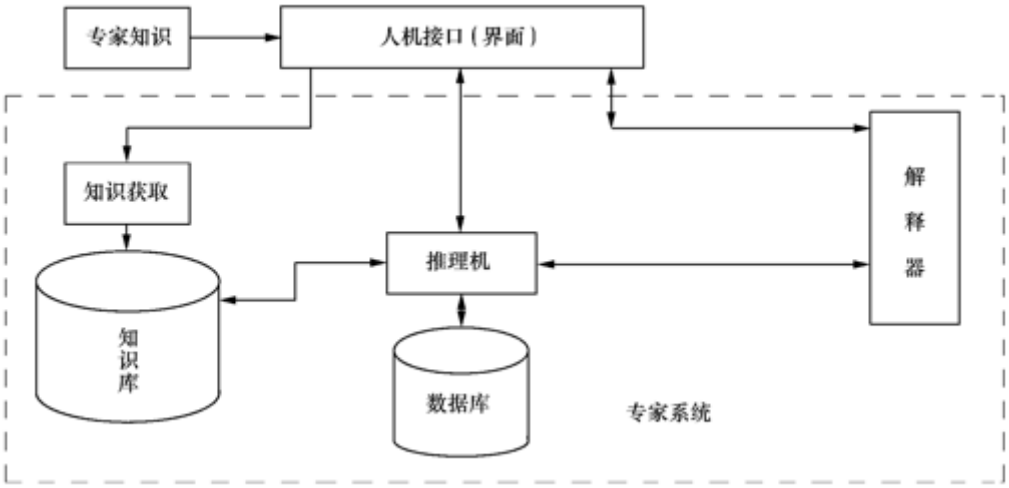


图 27

特点：具有专家水平的专业知识、能进行有效的推理、启发性、灵活性、透明性、交互性。

结构：由人机交互界面、知识库、推理机、解释器、综合数据库、知识获取等6个部分构成

工作原理：根据知识库中的知识和用户提供的事实进行推理，不断地由已知的前提推出未知的结论即中间结果，并将中间结果放到数据库中，作为已知的新事实进行推理，从而把求解的问题由求知状态转换为已知状态

图示与公式

$$y_j(t) = f\left(\sum_{i=1}^{n} w_{ji}x_i - \theta_j\right)$$

式中，θ_j为神经元单元的偏置（阈值，bias），w_{ji}为权重（连接权系数，weight），n为输入信号数目，y_j为神经元输出，t为时间，$f(_)$为激活（激发，activation function）函数，决定节点（神经元）的输出。

图 12

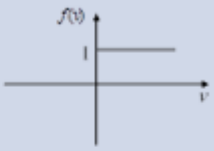
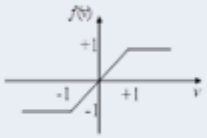
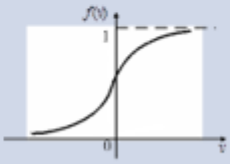
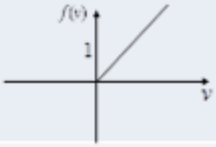
激活函数	表达形式	图形	解释说明
域值函数（阶梯函数）	$f(v)=\begin{cases}1 & v\geq 0\\ 0 & v<0\end{cases}$		当函数的自变量小于0时，函数的输出为0；当函数的自变量大于或等于0时，函数的输出为1，用该函数可以把输入分成两类。
分段线性函数	$f(v)=\begin{cases}1, & v\geq 1\\ v, & -1<v<1\\ -1, & v\leq -1\end{cases}$		该函数在（-1，+1）线性区内的放大系数是一致的，这种形式的激活函数可以看作是非线性放大器的近似。
非线性转移函数 sigmoid	$f(v)=\frac{1}{1+e^{-v}}$		单极性S型函数为实数域R到[0，1]闭集的连续函数，代表了连续状态型神经元模型。其特点是函数本身及其导数都是连续的，能够体现数学计算上的优越性。
Relu函数	$f(v)=\begin{cases}v, & v\geq 0\\ 0, & v<0\end{cases}$		这是近年来提出的激活函数，它具有计算简单、效果更佳的特点，目前已经有取代其他激活函数的趋势。

图 13

人工智能 · 习题

人工智能题

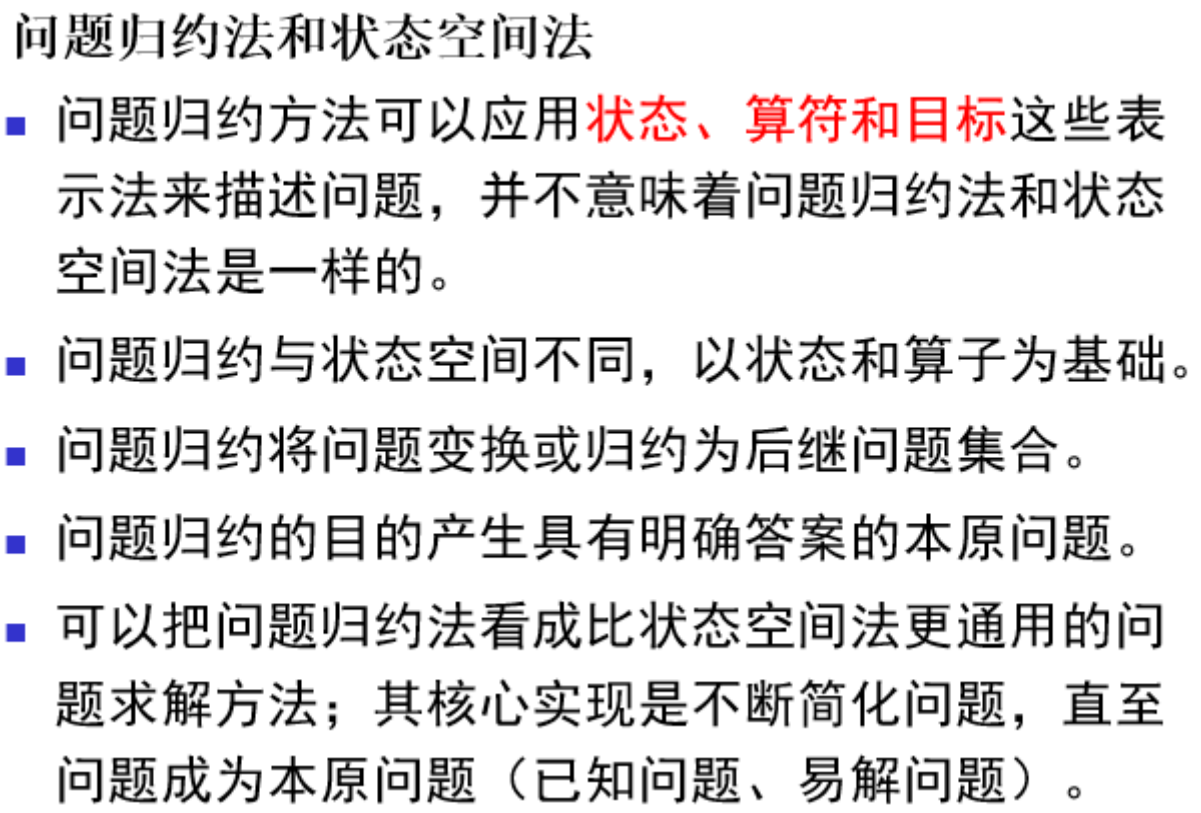
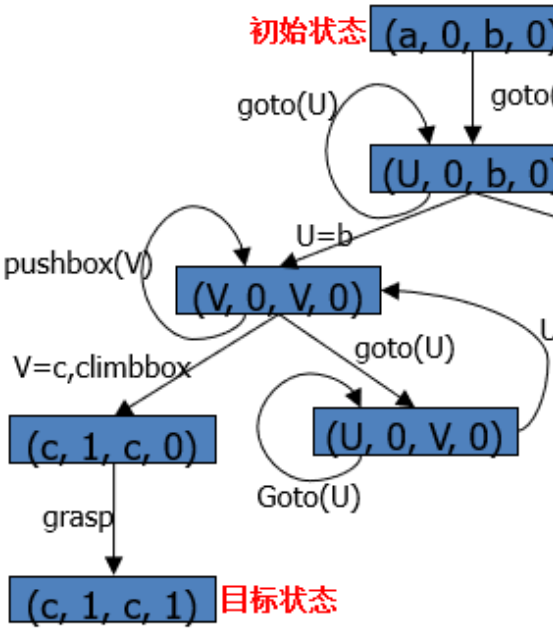


图 1



状态空间的图示形式称为状态空间图

✓节点(Node)：图形上的汇合点，用来表示状态、事件和时间关系的汇合，也可用来指示通路的汇合。

✓弧线(Arc)：节点间的连接线，表示算符；

✓有向图(Directed Graph)：一对节点用弧线连接起来，从一个节点指向另一个节点，这种图叫有向图。

✓后继节点(Descendant node)与父辈节点(Parent node)：如果某条弧线从节点n_i指向节点n_j，那么节点n_j就叫做节点n_i的后继节点或后裔，而节点n_i叫做节点n_j的父辈节点或祖先。

✓路径(Path)：某个节点序列$(n_{i1},n_{i2},\ldots,n_{ik})$当$j=2,3,\ldots,k$时，如果对于每一个$n_{i,j-1}$都有一个后继节点$n_{ij}$存在，那么就把这个节点序列叫做从节点$n_{i1}$至节点$n_{ik}$的长度为$k$的路径。

✓可达到的节点：如果从节点n_i至节点n_j存在一条路径，那么就称节点n_j是从节点n_i可达到的节点。或者称节点n_j为节点n_i的后裔，而且称n_i为为节点n_j的祖先。

✓代价(Cost)：用$c(n_i,n_j)$来表示从节点n_i指向节点n_j的那段弧线的代价。两节点间路径的代价等于连接该路径上各节点的所有弧线代价之和。

显式表示：各节点及其具有代价的弧线由一张表明确给出。表可能列出该图中的每一节点、其后继节点及连接弧线的代价。例如，邻接表、邻接矩阵

隐式表示：集合{si}作为起始节点是已知的。后继节点算符Γ也是已知的，它作用于任一节点以产生该节点的全部后继节点和各连接弧线的代价。例如，棋局

图 2

- 例，表达式 P[x, f(y), B]的4个置换为
  - s1={ z/x, w/y };
  - s2={ A/y };
  - s3={ q(z)/x , A/y };
  - s4={ c/x , A/y }

用Es表示一个表达式E用置换s所得到的表达式的置换。

于是，P[x, f(y), B]的4个置换如下：

- P[x, f(y), B] s1 = P[z, f(w), B]
- P[x, f(y), B] s2 = P[x, f(A), B]
- P[x, f(y), B] s3 = P[q(z), f(A), B]
- P[x, f(y), B] s4 = P[c, f(A), B]

图 3

- 例: 表达式集{P(x, f(y), B), P(x, f(B), B)}的合一者为

  s={A/x, B/y}

  因为

  P(x, f(y), B) s=P(x, f(B), B)s=P(A, f(B), B)

  即s使{P(x, f(y), B), P(x, f(B), B)}成为单一形式

- 例： 设有公式集 E={P(x, y, f(y)), P(a, g(x), z)}

  则下式是它的一个合一

  s={a/x, g(a)/y, f(g(a))/z}

图 4

例如： E_1=P(a,x,f(g(y))), E_2=P(z,f(a),f(u))求*mgu* 。

解:

(1) 令W={E_1,E_2}={P(a,x,f(g(y))) ， P(z,f(a),f(u))}

(2) W_0=W， g_0=[ ]

(3) W_0未合一，从左到右找不一致集，有D_0={a, z}

(4) 取v_0=z,t_0=a

(5) 令g_1= g_0{t_0/v_0}={a/z}

W_1= W_0 g_1= {P(a,x,f(g(y))) ， P(a,f(a),f(u))}

图 5

(3)' W_1未合一，从左到右找不一致集，有D_1={x, f(a)}

(4)' 取v_1=x,t_1=f(a)

(5)' 令g_2= g_1{t_1/v_1}={a/z, f(a)/x}

W_2= W_1 g_2= {P(a,f(a),f(g(y))) , P(a,f(a),f(u))}

(3)" W_2未合一，从左到右找不一致集，有D_2={g(y), u)}

(4)" 取v_2=u,t_2=g(y)

(5)" 令g_3= g_2{t_2/v_2,}={a/z, f(a)/x, g(y)/u}

W_3= W_2 g_3= {P(a,f(a),f(g(y))) , P(a,f(a),f(g(y)))}

(3)"'W_3已合一，这时g_3 ={a/z, f(a)/x, g(y)/u}

图 6

✓例如：用语义网络表示

- 李新的汽车的款式是“捷达”、银灰色。
- 王红的汽车的款式是“凯越”、红色。
- 李新和王红的汽车均属于具体概念,可增加“汽车” 这个抽象概念。

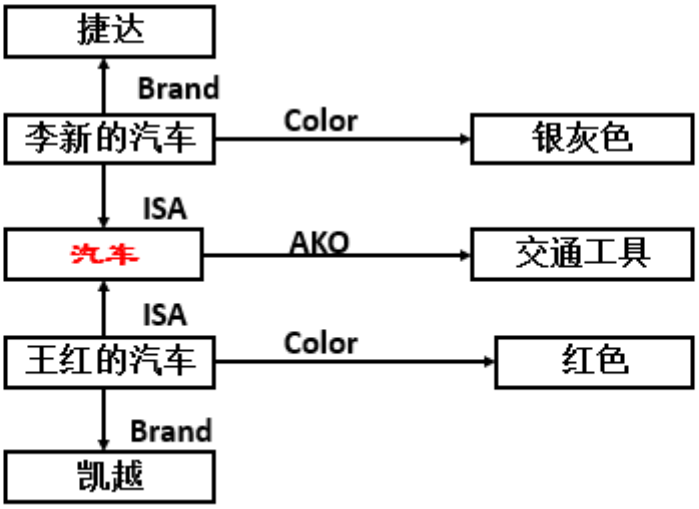


图 7

例. 我椅子的颜色是咖啡色的；椅子包套是皮革；椅子是一种家具；座位是椅子的一部分；椅子的所有者是X；X是个人

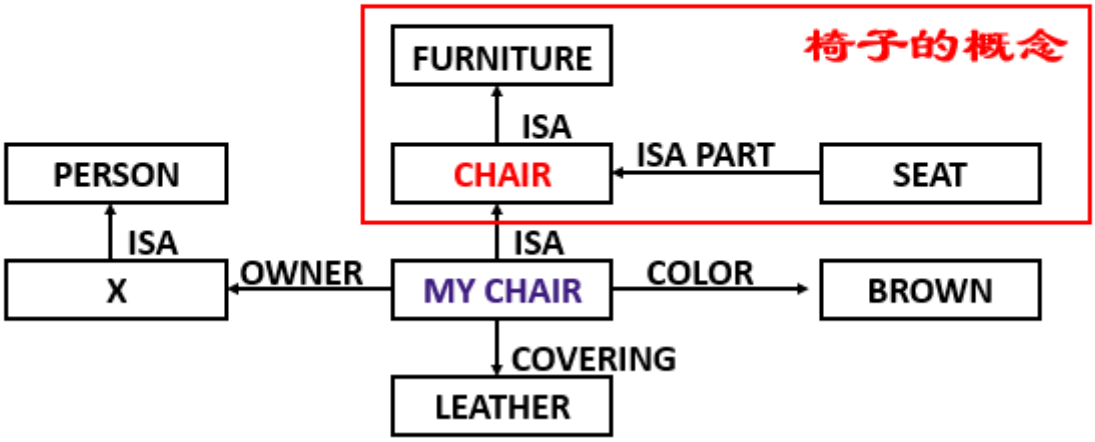


图 8

✓例如： 用语义网络表示 “小燕从春天到秋天占有巢-1”

□需要设立一个“占有权”的情况节点，表示占有物和占有时间等。

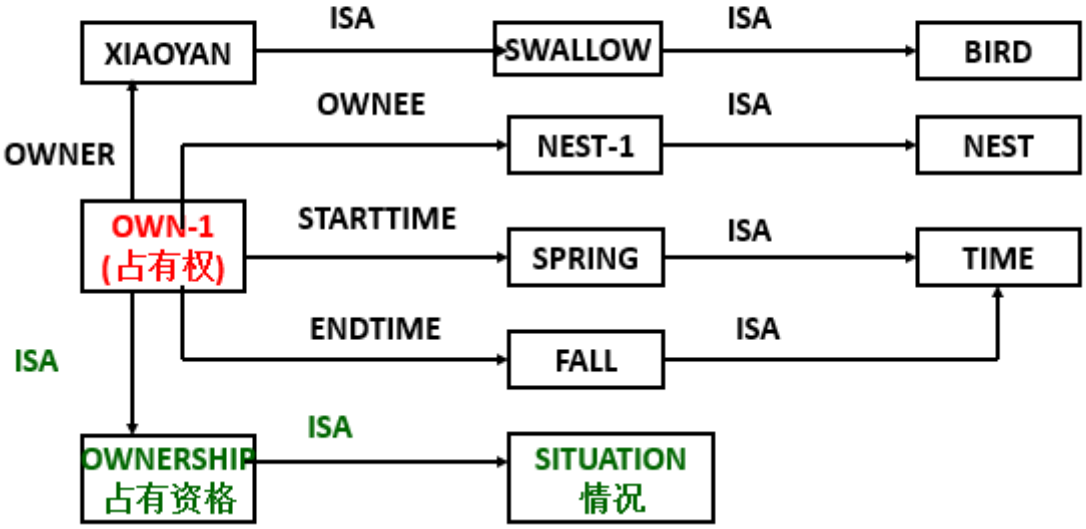


图 9

多元关系表示方法：增加事件节点

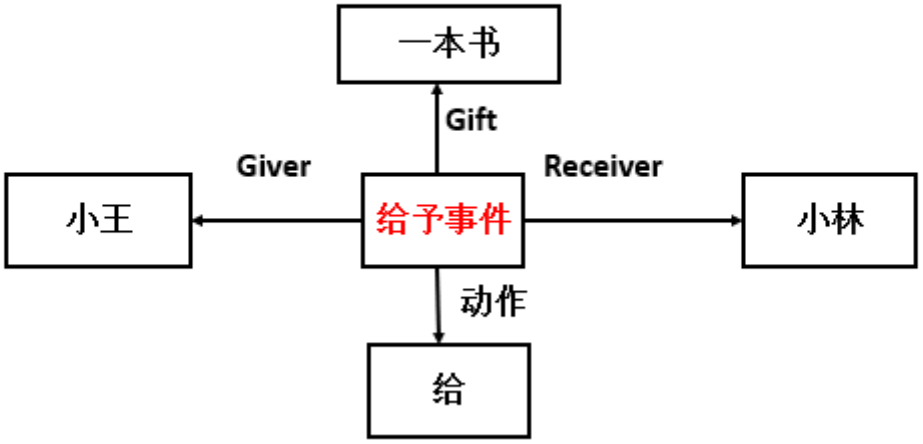


图 10

✓例如： 用语义网络表示“北京大学和清华大学两校篮球队在北大进行一场比赛的比分是85：89”。

- 三元关系
- 需要设立一个“球赛”的事件节点
- 引入事件节点G25来表示这场特点的球赛

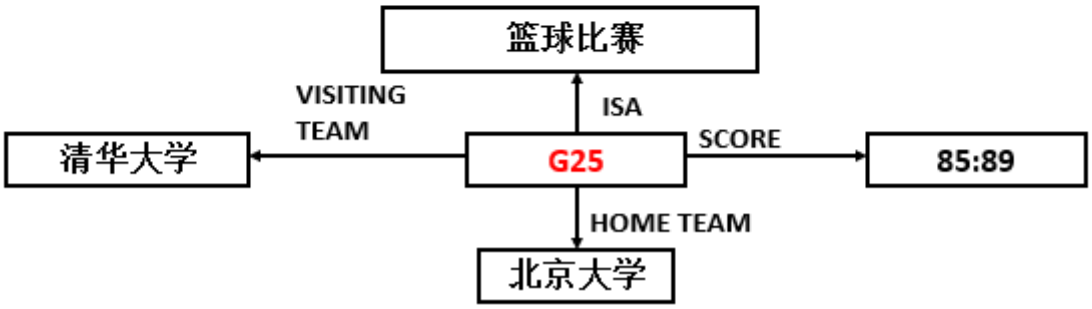


图 11

- 连接词和量词的表示

✓**合取和析取的表示**：可通过增加合取节点和析取节点来实现

✓例如：用语义网络表示：“参赛者有教师有学生，参赛者的身高有高有低”

✓分析参赛者的不同情况，可得到以下四种情况：

- A 教师、高；
- B 教师、低；
- C 学生、高；
- D 学生、低

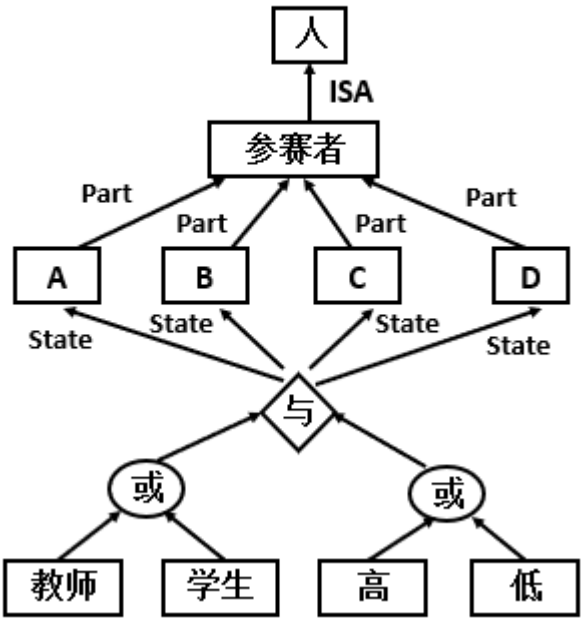


图 12

✓**否定的表示**：

□**基本语义关系的否定**：可通过在有向弧上直接标注该基本语义关系的否定的方法来解决。

□例如：用语义网络表示“书不在桌子上”



□**一般语义关系的否定**：可通过引进“非”节点来表示

□例如：用语义网络表示“小王没有给小林一本书”

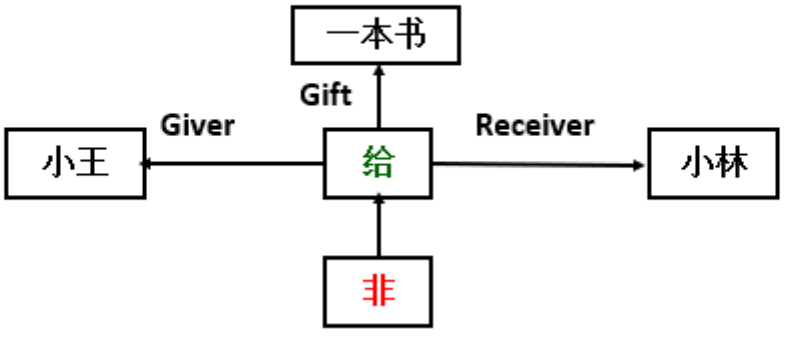


图 13

✓例如：用语义网络表示：“如果学校组织大学生机器人竞赛活动，那么李强就参加比赛”

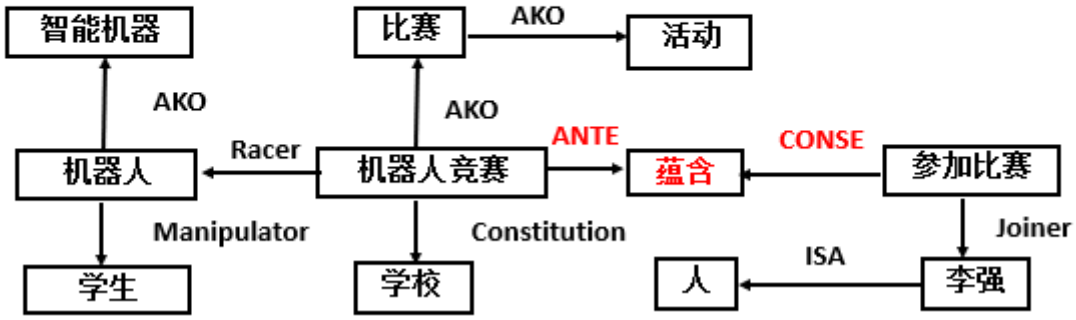
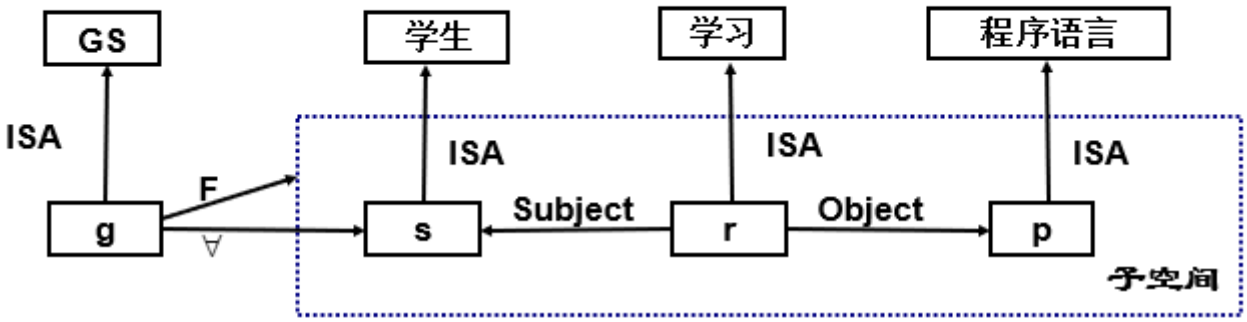


图 14

□“每个学生都学习了一门程序设计语言”



- GS：是一个概念结点，它表示具有全称量化的一般事件。
- g：是一个实例结点，代表GS 中的一个具体例子，如上所提到的事实。
- s：是一个全称变量，表示任意一个学生。
- r：是一个存在变量，表示某一次学习。
- p：是一个存在变量，表示某一门程序设计语言。
- F：弧“F”说明它所代表的子空间及其具体形式
- ∀：弧“∀”说明它所代表的全称量词。

图 15

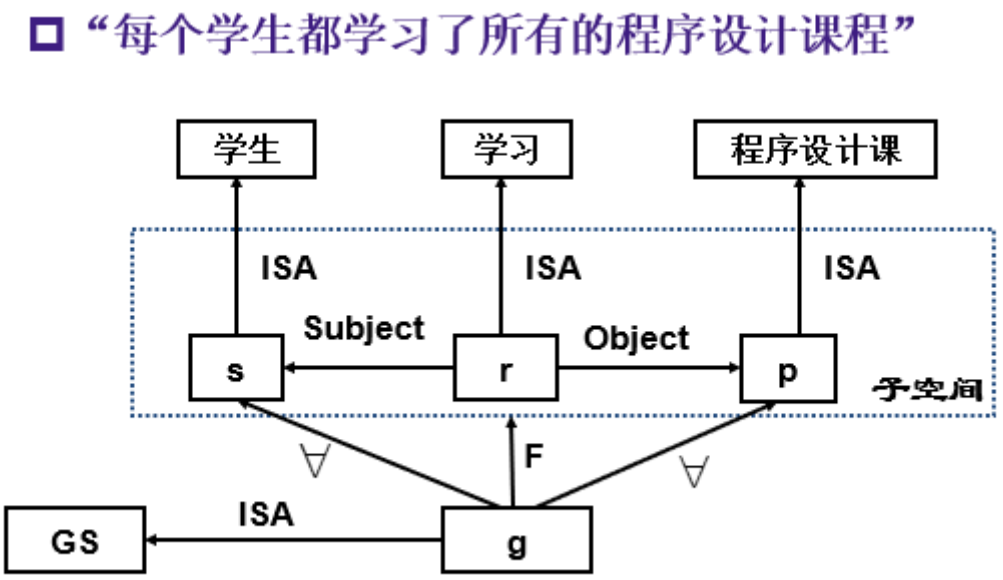

“每个学生都学习了所有的程序设计课程”
学生
学习
程序设计课
ISA
ISA
ISA
Subject
Object
s
r
p
子空间
∀
F
∀
ISA
GS
g

图 16

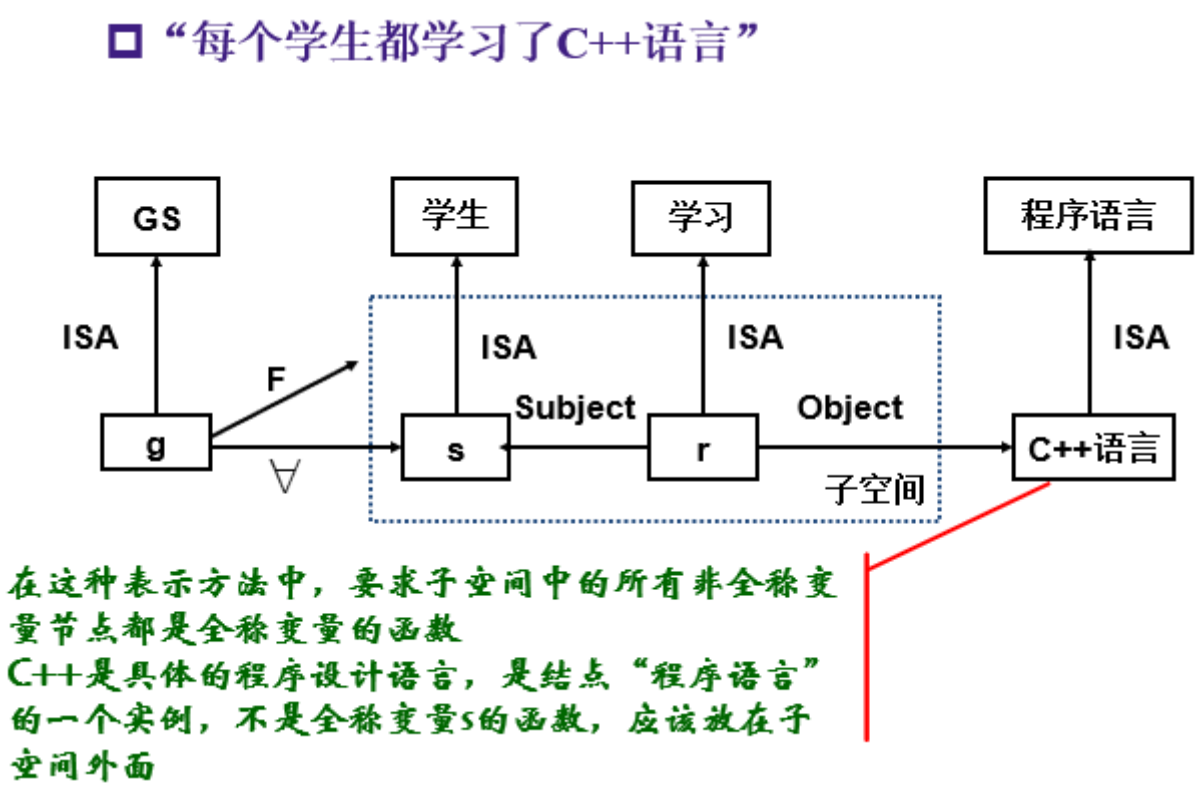
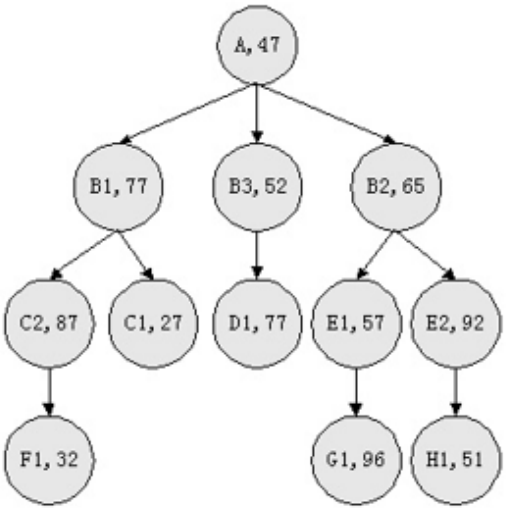

“每个学生都学习了C++语言”
GS
学生
学习
程序语言
ISA
ISA
ISA
ISA
F
Subject
Object
g
s
r
C++语言
∀
子空间
在这种表示方法中，要求子空间中的所有非全称变量节点都是全称变量的函数
C++是具体的程序设计语言，是结点“程序语言”的一个实例，不是全称变量s的函数，应该放在子空间外面

图 17

例：从某王姓家族的四代中找王A的后代且其寿命为X的人。

王A：寿命47，有儿子王B1、王B3、王B2
王B1：寿命77，有儿子王C1、王C2
王B3：寿命52，有儿子王D1
王B2：寿命65，有儿子王E1、王E2
王F1：寿命32
王G1：寿命96
王C2：寿命87，有儿子王F1
王D1：寿命77，没有儿子
王E1：寿命57，有儿子王G1
王E2：寿命92，有儿子王H1
王C1：寿命27，没有儿子
王H1：寿命51



若X=57，下面讨论一种可通用的图搜索策略求解此问题。

如果是一个N代的家族表中找其寿命为X的人，我们最可能用的手工方法是从家族表的开始往下，例中还要求所找的人是某人的后代，就比较复杂了。

如果用图来表示，就很容易了。图中把姓氏省去，每个成员的后代按例子中给出名字的先后顺序。

图 18

- 宽度优先搜索的例子：八数码难题
  - ✓在3×3的方格棋盘上，分别放置了标有数字1、2、3、4、5、6、7、8的八张牌，初始状态S_0，目标状态S_g，如下图所示。要求应用宽度优先搜索策略寻找从初始状态到目标状态的解路径。

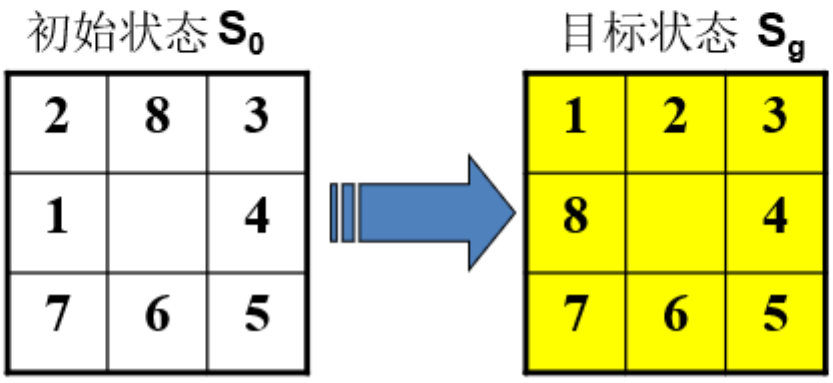


图 19

八数码难题的宽度优先搜索树

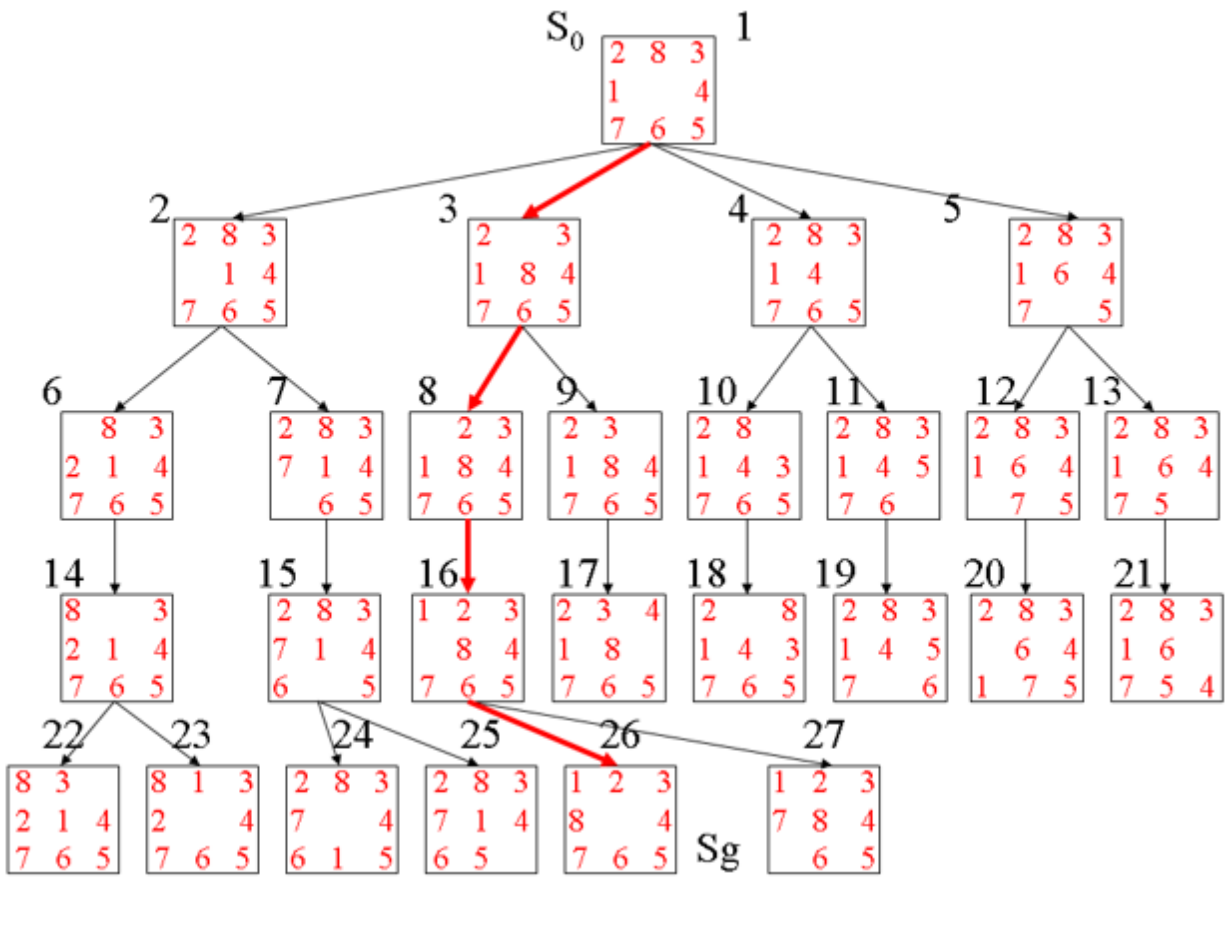


图 20

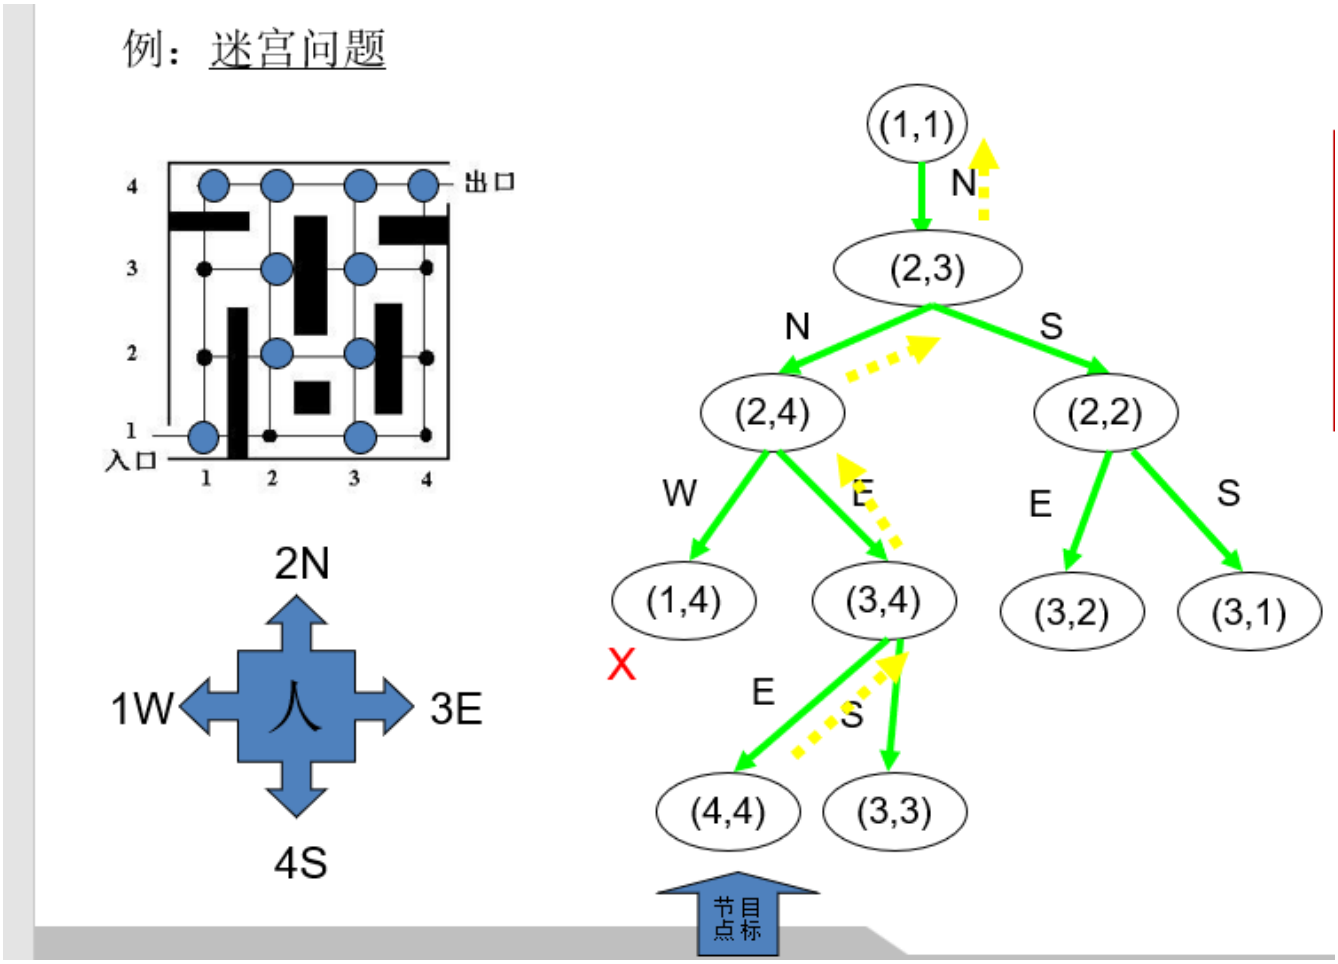

例：迷宫问题
出口
入口
4
3
2
1
1
2
3
4
2N
1W
人
3E
4S
(1,1)
N
(2,3)
N
S
(2,4)
(2,2)
W
E
E
S
(1,4)
(3,4)
(3,2)
(3,1)
X
E
S
(4,4)
(3,3)
节目点标

图 21

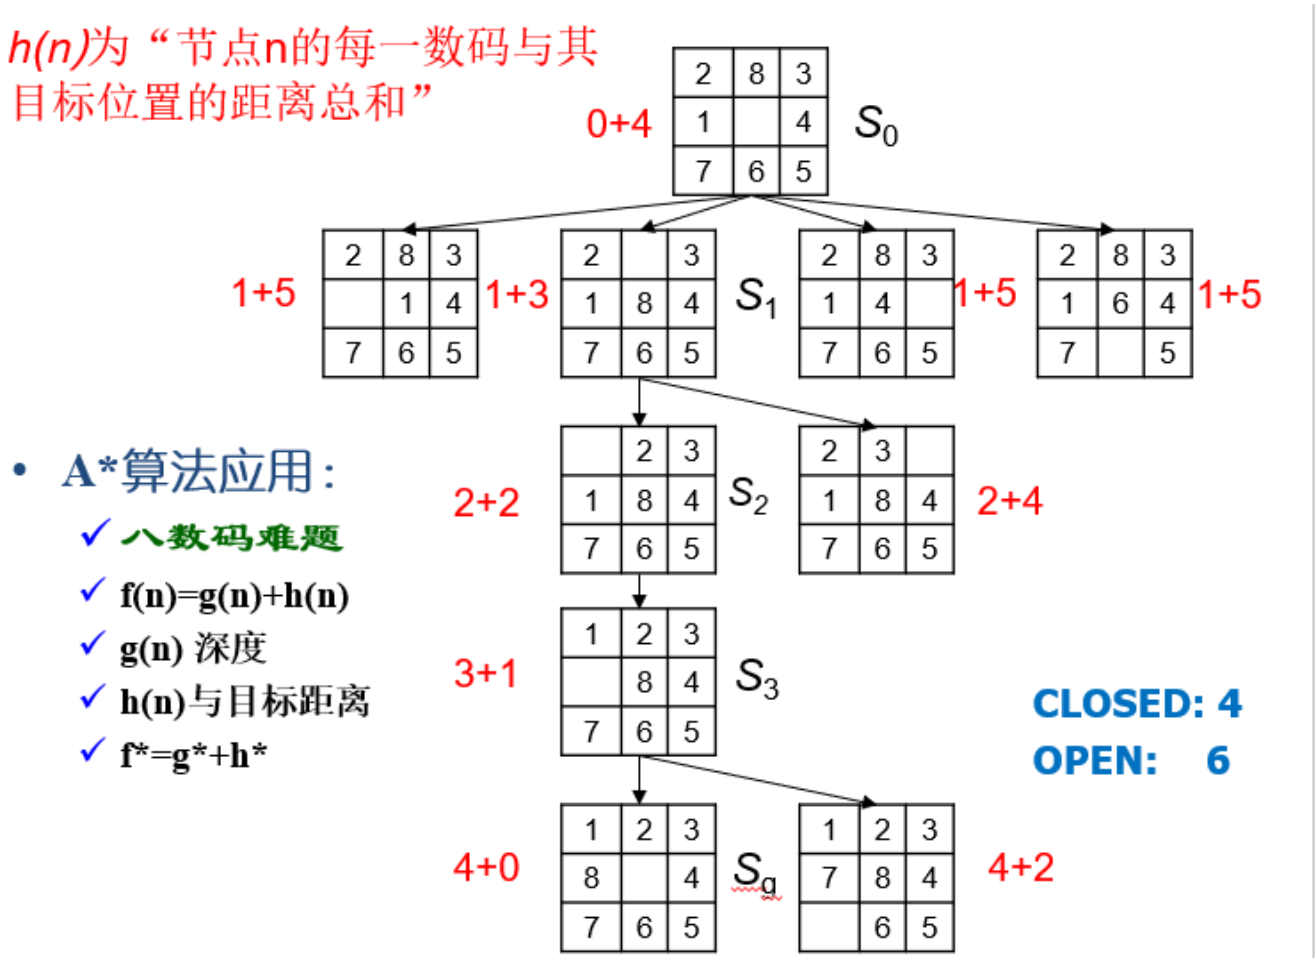


图 22

给定一个新样本Chinese Chinese Chinese Tokyo Japan，对其进行分类。

id	doc	类别In c=China?
1	Chinese Beijing Chinese	yes
2	Chinese Chinese Shanghai	yes
3	Chinese Macao	yes
4	Tokyo Japan Chinese	no

图 23

- 该文本用属性向量表示为
- d=(Chinese, Chinese, Chinese, Tokyo, Japan)
- 类别集合为Y={yes, no}。

•先验概率计算如下：
类yes下总共有8个单词,类no下总共有3个单词,训练样本单词总数为11,因此

$$P(YES)=\frac{8}{11} \qquad P(NO)=\frac{3}{11}$$

id	doc	类别In c=China?
1	Chinese Beijing Chinese	yes
2	Chinese Chinese Shanghai	yes
3	Chinese Macao	yes
4	Tokyo Japan Chinese	no

图 24